

Vorlesung: Statistik I

Prof. Dr. Simone Abendschön

4 Vorlesung am 9.11.23

Plan für heute

- Verteilungsformen (grafische Anschauung)
- Einführung Notation: Summenzeichen
- Univariate Datenanalyse: Lagemaße (auch: Maße der zentralen Tendenz)

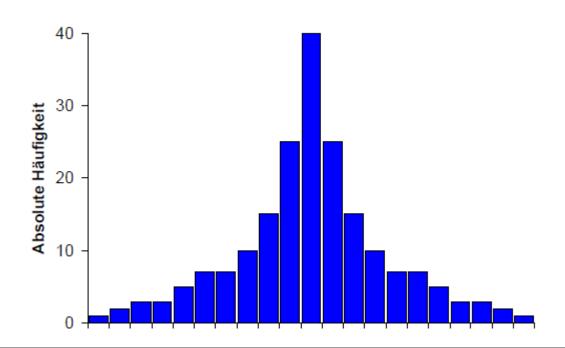
- Verständnis des Aufbaus einer Datenmatrix (letzte Woche)
- Grundlegende Kenntnis tabellarischer und grafischer Darstellungsformen von univariaten statistischen Informationen (letzte und diese Woche)
- Kenntnis und Anwendung des Summenzeichens
- Kenntnis und Verständnis von Lagemaßen der univariaten Statistik
- Bestimmung und Berechnung von Lagemaßen der univariaten Statistik: Modus, Median, arithmetisches Mittel, Quantile

- Empirisch erhobene Daten k\u00f6nnen anhand von H\u00e4ufigkeitsverteilungen tabellarisch zusammengefasst oder grafisch dargestellt werden
- Darüber hinaus lässt sich auch die Form einer Verteilung beschreiben

Häufige Verteilungsformen

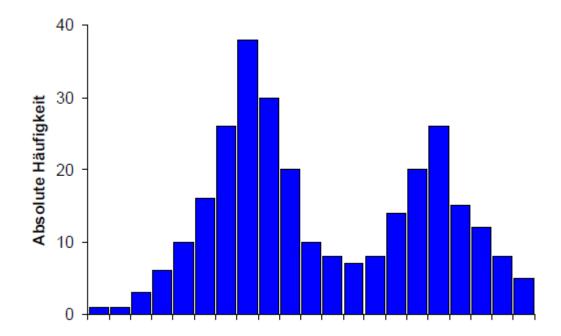
Symmetrische Verteilung

 "eingipflig", ungefähr die gleiche Anzahl von Werten links und rechts des Gipfels



Bimodale Verteilung

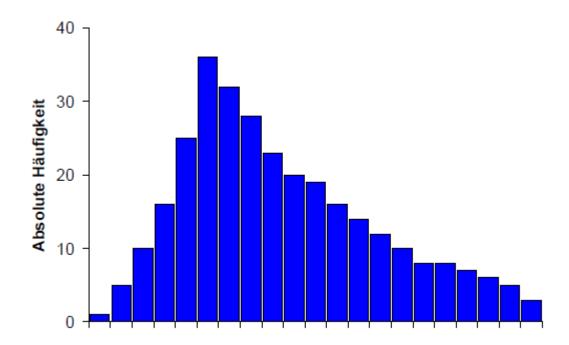
Zwei Gipfel, evtl. 2 Subgruppen



Häufige Verteilungsformen

Linkssteile bzw. rechtsschiefe Verteilung (positive Schiefe)

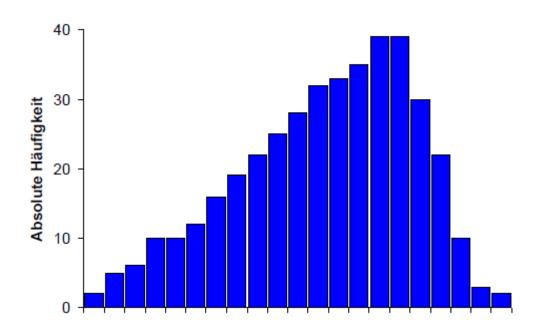
 Höchste Datenwerte recht weit vom Zentrum der Verteilung entfernt (z.B. Einkommen)



Häufige Verteilungsformen

Rechtssteile bzw. linkssschiefe Verteilung (negative Schiefe)

 Niedrigste Datenwerte relativ weit vom Zentrum der Verteilung entfernt (z.B. Sterbealter in Deutschland)



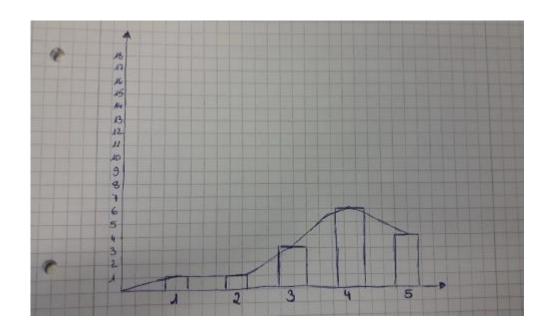
- Bitte skizzieren Sie ein Säulendiagramm für die absoluten Häufigkeiten der unten dargestellten Tabelle (Merkmalsausprägungen: Kein Abschluss = 1, Hauptschule = 2, Realschule = 3, Abitur = 4,Universität = 5)
- 2) Beschreiben Sie die Verteilungsform.

Bildungsab- schluss	fx_k
Keiner (1)	1
Hauptschule (2)	1
Realschule (3)	3
(Fach-)Abitur (4)	6
Universität (5)	4

Übung

- 1) Bitte skizzieren Sie ein Säulendiagramm für die absoluten Häufigkeiten der unten dargestellten Tabelle (Merkmalsausprägungen: Kein Abschluss = 1, Hauptschule = 2, Realschule = 3, Abitur = 4,Universität = 5)
- 2) Beschreiben Sie die Verteilungsform.

Bildungsab- schluss	fx_k
keiner	1
Hauptschule	1
Realschule	3
(Fach-)Abitur	6
Universität	4



Plan für heute

- Verteilungsformen (grafische Anschauung)
- Einführung Notation: Summenzeichen
- Univariate Datenanalyse: Lagemaße (auch: Maße der zentralen Tendenz)

Σ (,Sigma')

- Vereinfacht die Darstellung einer Menge von Summanden zu einer Summe
- Beispiel: Was ist die Summe aller Realisationen der Variablen X (Alter)?

Person	Alter
1	21
2	20
3	21
4	20
5	23
6	25
7	20
8	23

$$X_1 + X_2 + X_3 + X_4 + X_5 + X_6 + X_7 + X_8 = 173$$

$$= \sum_{i=1}^{n} x_i$$

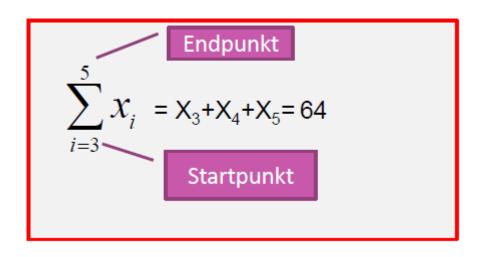
Sprich: "Die Summe aller x_i -Werte für Merkmalsträger i = 1 bis Merkmalsträger n"

Summenzeichen

$$\sum_{i=1}^{n} x_i$$

- Unterhalb des Summenzeichens steht der Laufindex i
- i kennzeichnet konventionsgemäß einen einzelnen Fall
- Nach dem Gleichheitszeichen folgt der Wert, mit dem die Summierung beginnt (in unserem Fall der 1. Wert)
- Oberhalb der Summenzeichens steht der letzte Wert des Index, hier n
- Bei der Summenbildung wird zunächst der erste Indexwert verwendet
- Anschließend wird dieser Wert um +1 erhöht, bis der letzte Wert erreicht ist
- Hinter dem Index steht der Ausdruck, der aufsummiert werden soll hier die Realisationen der Variablen X, also die Werte x_i

Person	Alter (Jahre)
1	21
2	20
3	21
4	20
5	23
6	25
7	20
8	23



Sprich: "Die Summe aller x_i -Werte für Merkmalsträger i = 3 bis Merkmalsträger 5"

 Vereinfachung: Wenn die Indexwerte eindeutig vorausgesetzt sind, wird oft der Start- und Endwert des Index nicht angegeben

$$\sum x_i$$
 anstelle von $\sum_{i=1}^n x_i$

Übung

Bitte bestimmen Sie die folgenden Werte für die in der nachstehenden Häufigkeitstabelle wiedergegebenen Daten:

- a) n=
- b) $\sum x_i$
- c) $\sum x_i^2$

x_k	absolute Häufigkeit $f_{\mathcal{X}_k}$
1	1
2	4
3	2
4	2
5	1

Plan für heute

- Verteilungsformen (grafische Anschauung)
- Einführung Notation: Summenzeichen
- Univariate Datenanalyse: Lagemaße (auch: Maße der zentralen Tendenz) als statistische Kennwerte

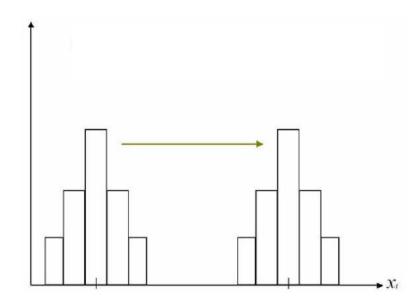
18

Was bisher geschah...

- Tabellen und grafische Darstellungen verschaffen einen globalen Eindruck von der Verteilung eines interessierenden Merkmals
- In Häufigkeitstabellen wird abgetragen, welche Merkmalsausprägung mit welcher (absoluten, prozentualen und/oder relativen kumulierten) Häufigkeit beobachtet wurde
- Bei kontinuierlichen Variablen bietet sich die tabellarische Zusammenfassung der Merkmalsausprägungen in Gruppen an
- Häufigkeitsverteilungen können grafisch z.B. als Säulendiagramm oder Histogramm dargestellt werden.
- Grafiken nehmen aber viel Platz ein, und der Vergleich von Verteilungsmerkmalen via Grafiken ist teilweise schwierig.
- → Informationsverdichtung nötig → statistische Kennwerte

- beschreiben spezifische Eigenschaften einer Merkmalsverteilung:
 Unterscheidung Lage- und Streu(ungs)maße
- Lagemaße (auch Maße der zentralen Tendenz):
 - Geben Auskunft über das Zentrum bzw. typische Werte einer Verteilung
 - Durch welchen Wert wird die Merkmalsverteilung am besten repräsentiert?
 - Wichtigste Lagemaße: Modus, Median und arithmetisches
 Mittel

- Lagemaße als "Mittelwerte"
- Wo auf der x-Achse befinden sich die Merkmalswerte einer Verteilung "im Mittel"?
- Beispiel: Identische Verteilungen, Unterschied lediglich in der "Lage"



Durch welchen Wert wird die Merkmalsverteilung am besten repräsentiert?

- → 3 Möglichkeiten, "Mittelwerte"
- Durch den Wert, der in der Verteilung am häufigsten vorkommt → Modus (auch Modalwert)
- Durch den Wert, der die Menge der Beobachtungseinheiten in zwei gleich große Teile teilt → Median (auch Zentralwert)
- 3. Durch den Durchschnitt aller Werte → Arithmetisches Mittel

Welches Lagemaß verwendet wird hängt auch vom Skalenniveau des interessierenden Merkmals ab!

Nominalskala	Ordinalskala	ab Intervallskala	
Ja	Ja	Ja	
Nein	Ja	Ja	
Nein	Nein	Ja	
	"Jein")		
	Ja Nein	Ja Ja Nein Ja	

Modus 24

- Definition: die Merkmalsausprägung, die in der Verteilung am häufigsten vorkommt
- Notation: x_{Mo}
- vor allem dann sinnvoll für die Charakterisierung einer Verteilung, wenn er sich deutlich von den anderen Werten abhebt

Studiengang x_k	Absolute Häufigkeit fx_k bzw. Hx_k
BA Social Sciences (1)	80
Jura (2)	10
Medizin (3)	40
BA Psycho (4)	30
Summe	160

•
$$x_{Mo}=1$$

Im Beispiel liegt der Modus für das Merkmal "Studiengang" bei der Merkmalsausprägung "1" (BASS)

Übung: Modus

Bei welchem Wert liegt in diesem Beispiel der Modus?

Schulnote	Absolute Häufigkeiten
1 ("sehr gut")	150
2 ("gut")	230
3 ("befriedigend")	400
4 ("ausreichend")	190
5 ("mangelhaft")	25
6 ("ungenügend")	5
Gesamt	1000

Lösung: Modus

Wo liegt in diesem Beispiel der Modus?

• $x_{Mo} = 3$

Schulnote	Absolute Häufigkeiten
1 ("sehr gut")	150
2 ("gut")	230
3 ("befriedigend")	400
4 ("ausreichend")	190
5 ("mangelhaft")	25
6 ("ungenügend")	5
Gesamt	1000

"Durch welchen Wert wird die Merkmalsverteilung am besten repräsentiert?

- → 3 Möglichkeiten
- Durch den Wert, der in der Verteilung am häufigsten vorkommt →
 Modalwert (auch Modus)
- Durch den Wert, der die Menge der Beobachtungseinheiten in zwei gleich große Teile teilt → Median (auch Zentralwert)
- 3. Durch den Durchschnitt aller Werte → Arithmetisches Mittel

Median

- Definition: diejenige Ausprägung, die in der Mitte einer geordneten Verteilung (nach ihrer Größe sortierten Messwerte) steht.
- Notation: \tilde{x}
- Der Median teilt die Verteilung einer Variablen in zwei Hälften, das bedeutet unter- und oberhalb des Medians liegen jeweils 50% der Untersuchungseinheiten
- Voraussetzung für die Bestimmung des Medians ist mindestens ordinales Skalenniveau

Median 30

 Berechnung unterscheidet sich, je nachdem ob eine gerade oder ungerade Anzahl von Messwerten vorliegt (für eine gerade Anzahl von Messwerten gibt es keine "Mitte")

• Die Position des Medians bei einer Verteilung mit ungerader Fallzahl entspricht dem Wert des Elements auf dem Rangplatz $\frac{n+1}{2}$

- Werte der Tabelle bereits aufsteigend geordnet
- Formel für Median bei ungerader Anzahl von Messwerten: $\tilde{x} = x_{\frac{n+1}{2}}$
- $\tilde{\chi} = \chi_{\frac{9+1}{2}}$

					Median				
Rang- platz	X ₍₁₎	X ₍₂₎	X ₍₃₎	X ₍₄₎	X ₍₅₎	X ₍₆₎	X ₍₇₎	X ₍₈₎	X ₍₉₎
Wert	28	32	38	41	42	42	55	59	78

$$\tilde{x}$$
=42

- Für eine Verteilung mit gerader Fallzahl kann dem Median keine ganze Zahl zugeordnet werden
- bestimmt sich dann als Mittelwert der beiden zentral gelegenen Realisationen
- Genauer: entspricht dem Mittelwert der Realisationen der beiden mittleren Rangplätze

$$\frac{n}{2}$$
 und $\frac{n}{2}+1$

→ Bei gerader Anzahl von Merkmalsträgern:

$$\tilde{x} = \frac{1}{2} * (x_{\frac{n}{2}} + x_{\frac{n}{2}+1})$$

Beispiel Median, gerades n

- Werte der Tabelle bereits aufsteigend geordnet
- Formel für Median bei gerader Anzahl von Messwerten:

$$\tilde{x} = \frac{1}{2} * (x_{\frac{n}{2}} + x_{\frac{n}{2}+1})$$

• \tilde{x} =0.5 (41+42) =41.5

	Median Median							
Rang- platz	X ₍₁₎	X ₍₂₎	x ₍₃₎	x ₍₄₎	X ₍₅₎	X ₍₆₎	X ₍₇₎	X ₍₈₎
Wert	28	32	38	41	42	42	55	59

Median – Übung

MAP-Frage:

"Bestimmen Sie den Median der folgenden Messwerte":

16,17,19,11,18,13,18,16

Median – kumulierte relative Häufigkeiten

- Medianbestimmung bei großem n
- Sind die Werte einer Häufigkeitstabelle nach der Größe geordnet, so entspricht der Median dem Wert, bei dem die kumulierten Anteilswerte mindestens 50% betragen

Median – kumulierte relative Häufigkeiten

 Sind die Werte einer Häufigkeitstabelle nach der Größe geordnet, so entspricht der Median dem Wert, bei dem die kumulierten Anteilswerte mindestens 50% betragen

Schulnote	Absolute Häufigkeiten	Relativer Anteil (%)	Kum. relative Häufigkeit (%)
"sehr gut"	150	15	15
"gut"	230	23	38
"befriedigend"	400	40	78
"ausreichend"	190	19	97
"mangelhaft"	25	2.5	99.5
"ungenügend"	5	0.5	100
Gesamt	1000		

"Durch welchen Wert wird die Merkmalsverteilung am besten repräsentiert?

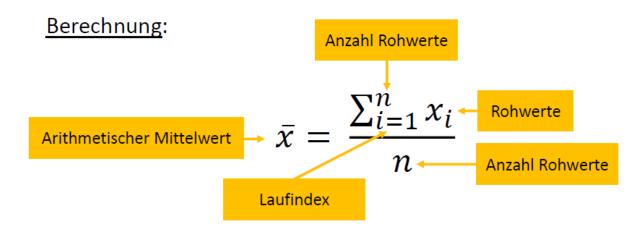
- → 3 Möglichkeiten
- Durch den Wert, der in der Verteilung am häufigsten vorkommt →
 Modalwert (auch Modus)
- Durch den Wert, der die Menge der Beobachtungseinheiten in zwei gleich große Teile teilt → Median (auch Zentralwert)
- 3. Durch den Durchschnitt aller Werte → Arithmetisches Mittel

- Definition: Summe aller Messwerte geteilt durch ihre Anzahl
- Notation: \bar{x}
- Umgangssprachlich: "der Mittelwert" oder "Durchschnitt"
- Berechnung?

- Definition: Summe aller Messwerte geteilt durch ihre Anzahl
- Notation: \bar{x}
- Umgangssprachlich: "der Mittelwert" oder "Durchschnitt"
- Berechnung:

$$\bar{x} = \frac{1}{n} * \sum_{i=1}^{n} x_i = \frac{\sum_{i=1}^{n} x_i}{n}$$

Berechnung: Arithmetisches Mittel



i = Laufindex Merkmalsträger (i = 1, ..., n)

 x_i = Merkmalsausprägung x des *i*-ten Merkmalsträgers

n =Anzahl der Merkmalsträger

Übung: Arithmetisches Mittel

- Gegeben ist folgende Urliste des metrisch skalierten Merkmals X: 2, 4, 5, 4, 3, 1, 3, 4, 2, 5 (n=10); wie lautet das arithmetische Mittel?
- Berechnung:

Übung: Arithmetisches Mittel

- Gegeben ist folgende Urliste des metrisch skalierten Merkmals X: 2, 4, 5, 4, 3, 1, 3, 4, 2, 5 (n=10); wie lautet das arithmetische Mittel?
- Berechnung:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n}$$

$$\bar{x} = \frac{1}{10} (2+4+5+4+3+1+3+4+2+5) = 3.3$$

- Berechnung bei kleinem n problemlos und intuitiv "händisch" möglich
- In der sozialwissenschaftlichen Praxis häufig große Fallzahlen (ALLBUS Umfrage, n=ca. 3000)
- Arithmetisches Mittel kann auch auf Basis der Häufigkeitstabelle berechnet werden
- Beispiel:

Schulnote	Absolute Häufigkeiten
1 ("sehr gut")	150
2 ("gut")	230
3 ("befriedigend")	400
4 ("ausreichend")	190
5 ("mangelhaft")	25
6 ("ungenügend")	5
Gesamt	1000

$$\bar{x}$$
 = (1*150)+(2*230)+(3*400)+(4*190)+(5*25) +(6*5)/1000=2725/1000= 2.725

Berechnung:

Merkmalsausprägung x der k-ten Kategorie

Häufigkeitsausprägung x der k-ten Kategorie

Arithmetischer Mittelwert

Laufindex

Auswertungskategorien

Anzahl Rohwerte

k = Laufindex "uber die Kategorien"(k = 1, ..., m)

m =Anzahl der Kategorien

 x_k = Merkmalsausprägung x der k-ten Kategorie

 f_{x_k} = Häufigkeitsausprägung x der k-ten Kategorie

n =Anzahl der Merkmalsträger

- enthält "am Meisten" Information über eine Verteilung (alle Messwerte werden berücksichtigt)
- Voraussetzung: (Pseudo-) metrisches Skalenniveau (z.B. auch Notendurchschnitt)
- Teilweise ohne sinnvolle empirische Entsprechung (z.B. "Deutsche Frauen gebären im Durchschnitt 1,58 Kinder")

Lagemaße

Welches Lagemaß verwendet wird hängt auch vom Skalenniveau des interessierenden Merkmals ab!

	Nominalskala	Ordinalskala	ab Intervallskala
Modus	Ja	Ja	Ja
Median	Nein	Ja	Ja
Arithmetisches Mittel	Nein	Nein	Ja
Quelle: Eigene Darstellung		"Jein")	

Ergänzung: Skalenniveau

- In der sozialwissenschaftlichen Forschungspraxis werden ordinale Skalenniveaus (bzw. Likert-Skalen oder "endpunktbenannte" Skalen) häufig als intervallskaliert behandelt (z.B. Einstellungsmessung)
- → "pseudo-/quasi-"metrisches Skalenniveau (i.d.R. ab 5 Ausprägungen)

RF.	Liste	203	vorle	gen!

Wie wichtig sind für Sie persönlich die einzelnen Lebensbereiche auf dieser Liste?

Der Wert 1 bedeutet *überhaupt nicht wichtig,* der Wert 7 *sehr wichtig.*Mit den Werten dazwischen können Sie die Wichtigkeit der Lebensbereiche abstufen.

	Überhaupt Sehr nicht wichtig	
	1 2 3 4 5 6 7	
Α	Eltern und Geschwister	
В	Freizeit und Erholung	
С	Schul- und Berufsausbildung	
D	Partnerschaft	
Ε	Politik	

- Vorteil: alle verfügbaren Informationen werden bei der Berechnung ausgeschöpft (alle Messwerte werden berücksichtigt)
- Nachteil: sensibel für Extremwerte ("Ausreißer") (daher v.a. geeignet, wenn eine symmetrische, unimodale Verteilung zugrunde liegt)

Beispiel: Arithmetisches Mittel

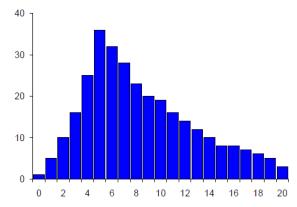
- Vorteil: alle verfügbaren Informationen werden bei der Berechnung ausgeschöpft (alle Messwerte werden berücksichtigt)
- Nachteil: sensibel für Extremwerte ("Ausreißer") (daher v.a. geeignet, wenn eine symmetrische, unimodale Verteilung zugrunde liegt)

Beispiel (Alter)	X ₁	X ₂	X ₃	X ₄	X ₅	X ₆	X ₇	X8	X9	\overline{X}
Gruppe 1	20	25	25	25	25	25	30	30	35	26,67
Gruppe 2	20	25	25	25	25	25	30	30	70	30,56

 Das Verhältnis von Modus, Median und arithmetischem Mittel erlaubt Rückschlüsse auf die Form der Verteilung

Linkssteile/rechtsschiefe Verteilung:

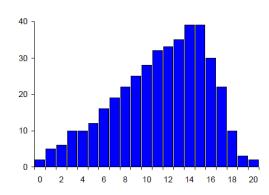
- Häufigste Ausprägung weiter links; Modus ist der kleinste der drei Mittelwerte
- Median liegt in der Mitte, daher größer als der Modus
- Arithmetisches Mittel wird stärker durch Ausreißer weit rechts beeinflusst, deshalb noch größer als der Median
- Modus< Median< arithmetisches Mittel



 Das Verhältnis von Modus, Median und arithmetischem Mittel erlaubt Rückschlüsse auf die Form der Verteilung

Rechtssteile/linksschiefe Verteilung:

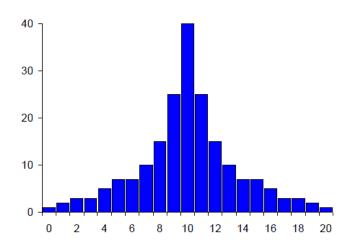
- Häufigste Ausprägung weiter rechts; Modus ist der größte der drei Mittelwerte
- Median liegt in der Mitte, daher kleiner als der Modus
- Arithmetisches Mittel wird stärker durch Ausreißer links beeinflusst, deshalb noch kleiner als der Median
- Modus> Median> arithmetisches Mittel



 Das Verhältnis von Modus, Median und arithmetischem Mittel erlaubt Rückschlüsse auf die Form der Verteilung

Symmetrische unimodale Verteilung:

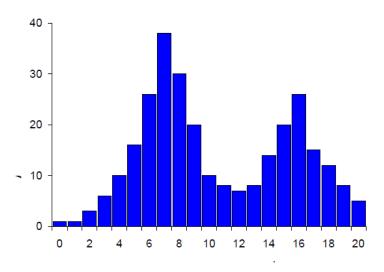
Modus, Median und arithmetisches Mittel nehmen sehr ähnliche Werte an



 Das Verhältnis von Modus, Median und arithmetischem Mittel erlaubt Rückschlüsse auf die Form der Verteilung

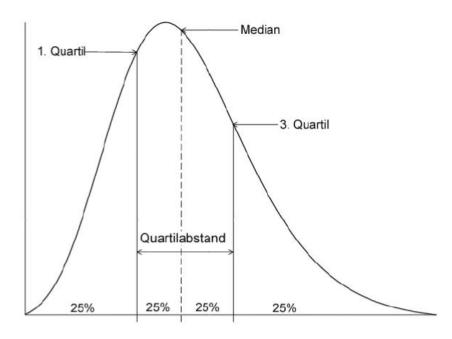
Bimodale Verteilung:

- Median und arithmetisches Mittel nehmen sehr ähnliche Werte an
- Modus teilweise nicht klar interpretierbar (ggfs. 2 Modalwerte angeben)



Quantile (auch Perzentile)

- Median entspricht dem Wert, bei dem die kumulierten relativen Anteile 50% erreichen oder übertreffen
- Analog hierzu lassen sich beliebige Quantile bilden (= Anteilswerte)
- Der Vergleich mehrerer Quantile erleichtert die Charakterisierung einer Verteilung. Zu den besonders gebräuchlichen Quantilen zählen die Quartile.
- Quartile unterteilen geordnete Daten in vier gleichgroße Gruppen (jeweils 25% der Datenwerte)



- 25% der Werte sind kleiner oder gleich und 75% der Werte sind größer oder gleich dem 1. Quartil (Q_{0.25})
- Das zweite Quartil ist der Median.
 50% der Werte sind kleiner oder gleich und 50% sind größer oder gleich dem Median.
- 75% der Werte sind kleiner oder gleich und 25% der Werte größer oder gleich dem 3. Quartil (Q_{0.75}).

Quantile (auch Perzentile)

- Quantilwerte k\u00f6nnen aus der H\u00e4ulfigkeitstabelle abgelesen werden (analog zur Bestimmung des Medians)
- Der Quantilwert ist die Ausprägung, bei der in der Spalte mit den kumulierten Anteilen bzw. kumulierten Prozentwerten erstmals der Quantilanteil erreicht oder überschritten wird

Beispiel Quartile

Wo liegt im Beispiel das 1. Quartil? Wo liegt das 3. Quartil?

Semesterzahl	Absolute Häufigkeit	%	Kumulierte %
10	1	9.1	9.1
11	2	18.2	27.3
12	3	27.3	54.6
13	2	18.2	72.8
14	1	9.1	81.9
15	1	9.1	91
20	1	9.1	100
Σ	11	100	100

Beispiel Quantile

- Wo liegt im Beispiel das 1. Quartil? → bei 11 Semestern
- Wo liegt das 3. Quartil?

Semesterzahl	Absolute Häufigkeit	%	Kumulierte %
10	1	9.1	9.1
11	2	18.2	27.3
12	3	27.3	54.6
13	2	18.2	72.8
14	1	9.1	81.9
15	1	9.1	91
20	1	9.1	100
Σ	11	100	100

Beispiel Quantile

- Wo liegt im Beispiel das 1. Quartil? → bei 11 Semestern
- Wo liegt das 3. Quartil?

Semesterzahl	Absolute Häufigkeit	%	Kumulierte %
10	1	9.1	9.1
11	2	18.2	27.3
12	3	27.3	54.6
13	2	18.2	72.8
14	1	9.1	81.9
15	1	9.1	91
20	1	9.1	100
Σ	11	100	100

Lernziele 61

- Kenntnis von Lagemaßen der univariaten Statistik
- Bestimmung und Berechnung von Lagemaßen der univariaten Statistik: Modus, Median, arithmetisches Mittel, Quantile