

Arbeitsblatt lineare Regression

Formeln:

Arithmetisches Mittel $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ (Gleiches Vorgehen für die Y-Werte)

Varianz $s^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$ (Gleiches Vorgehen für die Y-Werte)

Standardabweichung $s = \sqrt{s^2}$

Kovarianz $\text{cov}(x, y) = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{n}$

Lineare Regression: $b = \text{cov}/s_x^2$ $a = \bar{y} - b * \bar{x}$

Aufgaben:

- 1) Gegeben sind die folgenden vier Punkte:

x-Werte 0, 2, 3, 5

y-Werte 8, 3, 1, -2

- a) Bestimme die Mittelwerte von x und y, die Varianzen und die Standardabweichung s, die Kovarianz und die Gleichung der Regressionsgeraden $\hat{Y} = a + b * x$.

$$\bar{x} = 2,5 \quad \bar{y} = 2,5$$

$$s_x^2 = 3,25 \quad s_y^2 = 13,25$$

$$s_x = 1,8 \quad s_y = 3,64$$

$$\text{cov} = -6,5$$

$$\hat{Y} = 7,15 + (-2) * x$$

- b) Beschreibe die Gerade mithilfe der slope und des intercept.

Die Gerade schneidet die Y-Achse an der Stelle $Y = 7,15$ ($a = 7,15$) und hat eine Steigung von -2 ($b = -2$). Wenn X um eine Einheit größer wird, verändert sich Y um -2 Einheiten.

- 2) Gegeben sei die Regressionsgleichung $\hat{Y} = 4 - 0,5X$. Welche Aussage kann auf dieser Grundlage für die Korrelation zwischen X und Y getroffen werden?

Die Korrelation zwischen X und Y ist negativ, da die Gerade eine negative Steigung ($b = -0,5$) aufweist.


Gegeben sei die Regressionsgleichung $\hat{Y} = 2 + 4X$. Welche Aussage kann auf dieser Grundlage für die Korrelation zwischen X und Y getroffen werden?

Die Korrelation zwischen X und Y ist positiv, da die Gerade eine positive Steigung ($b = 4$) aufweist.

- 3) Gegeben sei eine lineare Regression mit $a = 12$ und $b = -1$. Wie lautet der vorausgesagte Wert für \hat{Y} an der Stelle $X = 5$?

$$\hat{Y} = 12 + (-1) * 5 = 7$$

- 4) Zeichne die Regressionsgerade $\hat{Y} = 2 + 2X$ in ein Koordinatensystem, in dem der Wert 0 auf der X-Achse nicht gleichzeitig die Y-Achse darstellt.



5) Beschreibe in eigenen Worten die Funktionsweise der linearen Regression und erkläre das Prinzip der „Ordinary-Least-Squares“.

- Vorhersage von Merkmalsausprägungen einer abhängigen Variable Y auf der Basis einer oder mehrerer unabhängiger Variablen X
- Es wird angenommen, dass der Zusammenhang zwischen X und Y linear ist, d.h. dass die Stärke und die Richtung des Zusammenhangs in jedem beliebigen Werteintervall auf der Variablen X gleich ist
- Y (Explanandum) soll durch X (Explanans) erklärt/vorhergesagt werden
- Korrelationen immer mit Unsicherheiten behaftet, wenn r nicht gleich 1 ist
 → Schätzung aller Werte so, dass der Vorhersagefehler über alle Werte hinweg möglichst gering bleibt
- Gleichung für die vorhergesagten Werte lautet $\hat{Y} = a + b * X$
 → Für jeden X -Wert gibt es einen beobachteten und einen vorhergesagten Y -Wert
 → Differenz zwischen Y und \hat{Y} ist das Regressionsresiduum e
- „Ordinary-Least-Squares“: Regressionsgerade soll so durch den Punkteschwarm gelegt werden, dass die Summe der quadrierten Regressionsresiduen minimal ist; Kriterium der kleinsten Quadrate; Minimierungsvorschrift ist erfüllt, wenn Regressionsparameter wie folgt bestimmt werden:

$$b = \text{cov}/s_x^2$$

$$a = \bar{y} - b * \bar{x}$$