

Vorlesung: Statistik I

Prof. Dr. Simone Abendschön 9. Einheit

- Zusammenhänge zwischen (pseudo-)metrischen Merkmalen
 - Allgemein
 - Hypothesen
 - Grafische Veranschaulichung
 - Zusammenhangsmaß Pearson's r
- Zusammenhangsmaß zwischen metrischem und gruppiertem Merkmal: PRE-Maß η 2 (Eta-Quadrat)

Zusammenhangsmaße

- Maße zur Berechnung, ob und wie stark zwei Merkmale miteinander statistisch zusammenhängen oder "korrelieren"
- Bei ordinalskalierten und metrisch skalierten Maßen auch Aussagen über die Richtung des Zusammenhangs möglich (positiv oder negativ)
- Pearson's r als Zusammenhangsmaß für zwei metrisch skalierte Merkmale (Korrelationskoeffizient)

Allgemein

Folgende Fragen stellen sich bei der statistischen Analyse von Merkmalszusammenhängen:

- Wie lässt sich die Form des Zusammenhangs zwischen X und Y beschreiben?
- Welche Richtung hat der Zusammenhang zwischen X und Y, d.h. ist er negativ oder positiv?
- Welche Stärke hat der Zusammenhang zwischen X und Y?
- (Lässt sich der in der Stichprobe ermittelte Zusammenhang auf die Population übertragen? → Inferenzstatik → nächstes Semester)

Zusammenhangsmaße

- Quantifizierung des Zusammenhangs durch Korrelationskoeffizienten
- Positive Korrelation:
 - Hohe Werte in der einen Variablen gehen mit hohen Werten in der anderen Variablen einher
 - Niedrige Werte in der einen gehen mit niedrigen Werten in der anderen Variablen einher
- Negative Korrelation:
 - Hohe (niedrige) Werte in der einen Variablen gehen mit niedrigen (hohen) Werten in der anderen Variablen einher
- Ggfs. auch kein Zusammenhang (Korrelation um 0)

Zusammenhangsmaße

Wann ist ein Messwert "hoch"? Wann ist ein Messwert "niedrig"?

- Vergleich anhand des arithmetischen Mittels der jeweiligen Variablen
 - Hohe Messwerte entsprechen Werten über dem arithmetischen Mittel
 - Niedrige Messwerte entsprechen Werten unter arithmet. Mittel

Stärke des Zusammenhangs zwischen zwei metrischen Variablen ergibt sich durch die Abweichung der Messwerte vom jeweiligen Mittelwert

In der quantitativen Sozialforschung entwickeln wir Hypothesen, die Zusammenhänge zwischen (mind.) 2 Merkmalen postulieren

Zusammenhangshypothesen

Beispiel: Je geringer der soziale Status desto schlechter der Gesundheitszustand im Rentenalter -> linearer Zusammenhang

Unterschiedshypothesen

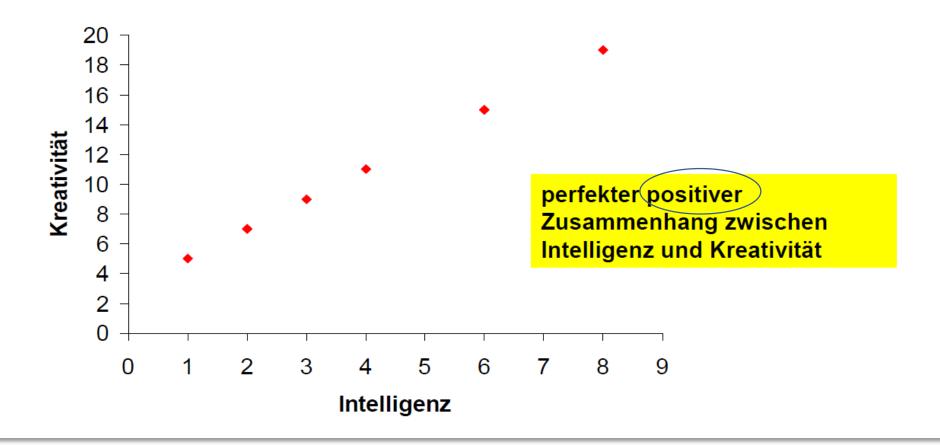
Beispiel: Rentner*innen mit hohem sozialen Status haben einen besseren Gesundheitszustand als Rentner*innen mit niedrigem sozialen Status

- Eine lineare Korrelation beschreibt einen linearen Zusammenhang zwischen zwei Variablen
- D.h. eine Veränderung von X geht mit einer dazu proportionalen Veränderung von Y einher
 - Beispiel: Je größer ein Mensch ist, desto schwerer ist er (Pro cm mehr Größe, bestimmte Grammzahl mehr)
- Korrelation trifft keine Aussage zur Kausalität
- Korrelationsanalyse misst nur, ob sich zwei Merkmale im Gleichklang bewegen

- Bi- (und multi)variate Analysen, um Zusammenhänge zwischen Merkmalen zu untersuchen
- Bei metrisch skalierten Daten:
 - Korrelationsanalyse (Pearson's r)
 - zunächst bietet sich eine grafische Darstellung an:
 Streudiagramm (auch Punktwolkendiagramm, Scatterplot)

- Zusammenhänge zwischen (pseudo-)metrischen Merkmalen
 - Allgemein
 - Hypothesen
 - Grafische Veranschaulichung
 - Zusammenhangsmaß Pearson's r
- Zusammenhangsmaß zwischen metrischem und gruppiertem Merkmal: PRE-Maß η 2 (Eta-Quadrat)

Zusammenhangshypothese: "Je intelligenter eine Person ist, desto kreativer ist sie auch".



Beispiel 2: Streudiagramm

Zusammenhangshypothese (S. Lehrbrief S. 63/64): "Je intelligenter eine Person ist, desto besser kann sie auch räumlich denken"

Tabelle 34: IQ und Testergebnis beim räumlichen Denken – Urliste

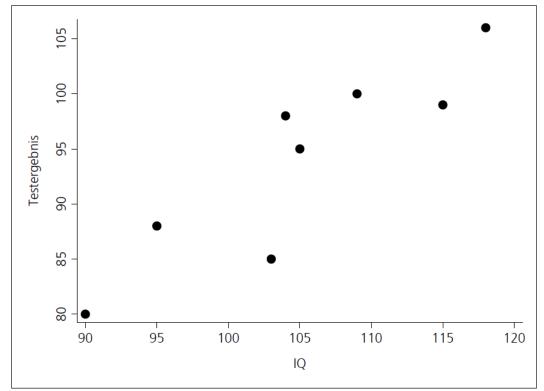
ID	IQ	Testergebnis
1	104	98
2	90	80
3	103	85
4	115	99
5	105	95
6	118	106
7	109	100
8	95	88

Quelle: Eigene Darstellung

Beispiel 2: Streudiagramm

Zusammenhangshypothese (S. Lehrbrief S. 63/64): "Je intelligenter eine Person ist, desto besser kann sie auch räumlich denken"

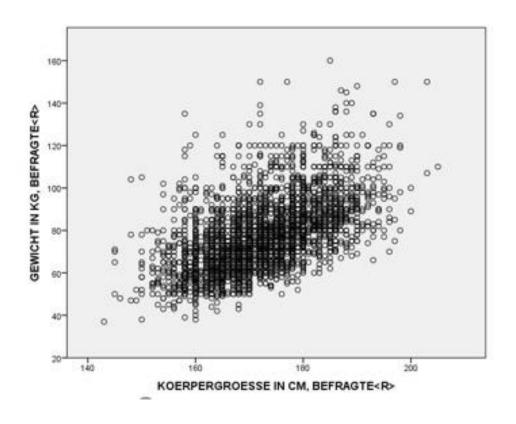
Abbildung 13: IQ und Testergebnis beim räumlichen Denken – Streudiagramm



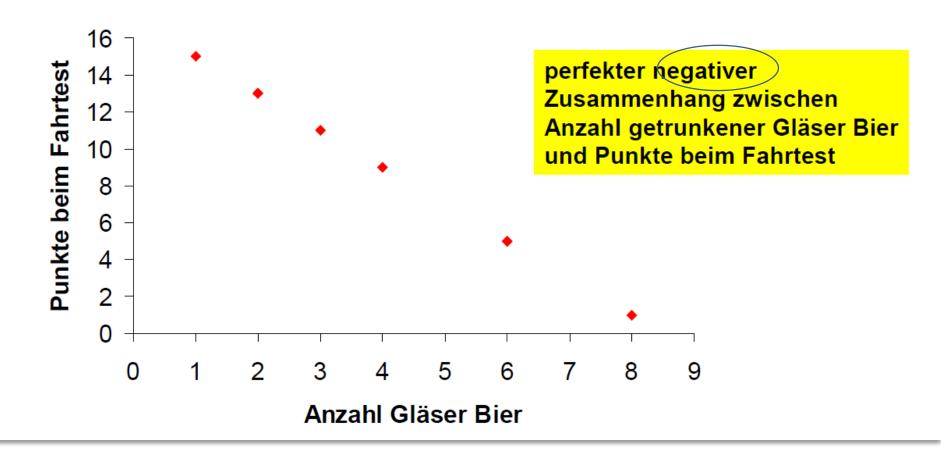
Quelle: Eigene Darstellung

Zusammenhangshypothese: "Je größer man ist, desto schwerer ist man auch" (Streudiagramm erstellt auf Basis des Allbus 2016)



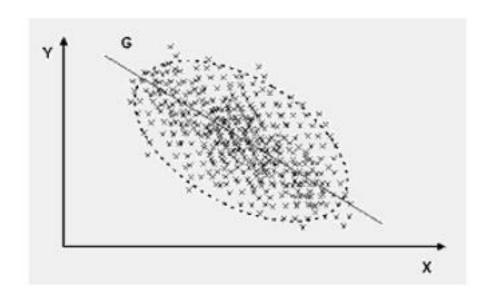


Zusammenhangshypothese: "Je mehr Alkohol man trinkt,, desto schlechter fährt man Auto"



Beispiel 5: Streudiagramm

Zusammenhangshypothese: "Je älter ein Auto ist, desto niedriger sein Verkaufswert" – negativer Zusammenhang

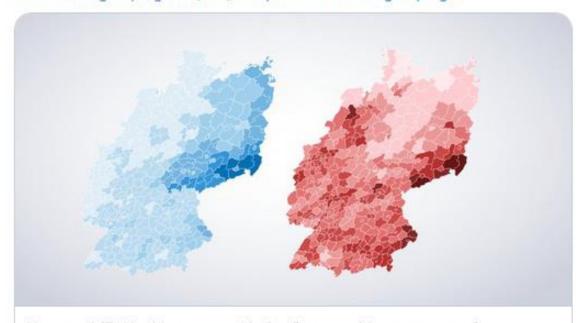




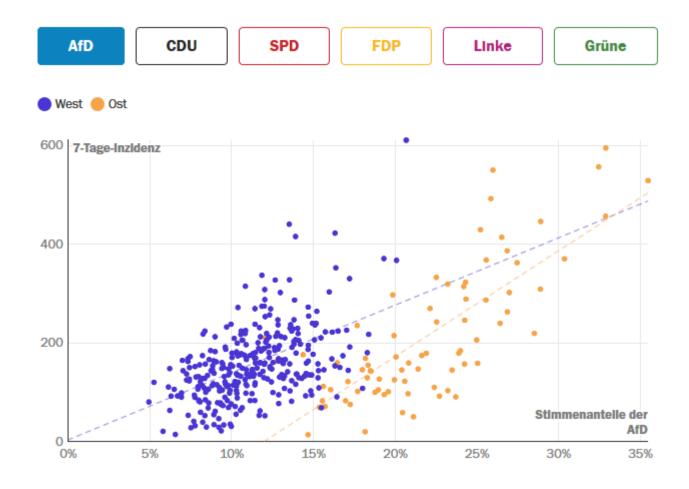
Matthias Quent @Matthias_Quent · 12. Dez. 2020

000

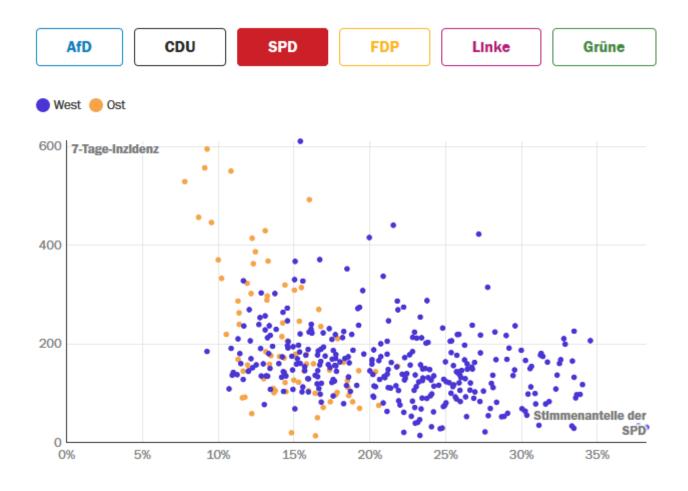
Hängen #AfD-Hochburgen und hohe #Coronazahlen zusammen?
@plateauton @Tagesspiegel hat unsere Berechnungen @IDZ_Jena überprüft
und ausgeweitet. Die Ergebnisse bestätigen die Korrelation.
interaktiv.tagesspiegel.de/lab/hotspots-u... via @tagesspiegel



Hängen AfD-Hochburgen und hohe Coronazahlen zusammen? Eine Analyse legt nahe, dass in Landkreisen mit großer AfD-Wählerschaft auch die Fallzahlen höher sind. Was ist dran? Wir rechnen nach. Ø interaktiv.tagesspiegel.de



https://interaktiv.tagesspiegel.de/lab/hotspots-und-rechte-haengen-afd-hochburgen-



https://interaktiv.tagesspiegel.de/lab/hotspots-und-rechte-haengen-afd-hochburgen-

Pearson's r

- Auch Bravais-Pearson Produktkorrelation
- Berechnet die Stärke des linearen Zusammenhangs zwischen zwei (pseudo-)metrisch skalierten Variablen
- Zwischenschritt zur Berechnung: Kovarianz

Kovarianz - Berechnung

Kovarianz beschreibt die gemeinsame Streuung zweier Merkmale

- 1) Abweichung vom Mittelwert für jedes Messwertepaar bestimmen
- 2) Gemeinsame Abweichung beider Messwerte von ihren Mittelwerten durch Multiplikation berechnen
- 3) Berechnung der Summe der Abweichungsprodukte
- 4) Berechnung des durchschnittliche Abweichungsprodukt (mittels Division durch n)

cov (x,y) =
$$\frac{\sum_{i=1}^{n} (x_i - \bar{x}) (y_i - \bar{y})}{n}$$

Wiederholung Varianz
$$\sigma^2 = \frac{1}{n} * \sum_{i=1}^n (x_i - \bar{x})^2 = \frac{\sum_{i=1}^n (x_i - \bar{x})^2}{n}$$

Kovarianz

- hoch positiv, wenn hohe positive Abweichungen mit hohen positiven Abweichungen einhergehen bzw. hohe negative Abweichungen mit hohen negativen Abweichungen
- hoch negativ, wenn hohe positive Abweichungen mit hohen negativen Abweichungen einhergehen und umgekehrt.
- gleich null, wenn die Richtung der Abweichungen vom Mittelwert in X nicht systematisch mit einer bestimmten Richtung der Abweichungen vom Mittelwert in Y einhergeht.

Kovarianz

- Aber: unstandardisiertes Maß, Größe ist abhängig von den jeweiligen Maßeinheiten der beiden Merkmale
- Vergleich zwischen Kovarianzen wird erschwert
- → Standardisierung mit dem Korrelationskoeffizienten Pearson's r anhand der Division durch das Produkt der Standardabweichungen beider Merkmale

Pearson's r

Pearson's r entspricht der anhand des Produkts der Standardabweichungen standardisierten Kovarianz

$$r = \frac{cov(x;y)}{s_x * s_y} = \frac{\sum_{i=1}^{n} (x_i - \bar{x}) * (y_i - \bar{y})}{\sqrt{\sum_{i=1}^{n} (x_i - \bar{x})^2 * \sum_{i=1}^{n} (y_i - \bar{y})^2}}$$

- Wertebereich von -1 bis +1 (siehe auch Spearman's Rho!),
- Vorzeichen zeigt Richtung der Korrelation an, Betrag die Stärke des Zusammenhanges
 - Negatives Vorzeichen: negativer Zusammenhang
 - Positives Vorzeichen: positiver Zusammenhang

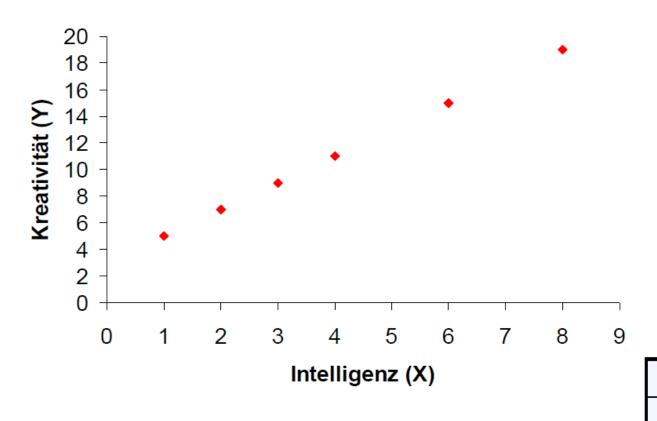
Interpretation Pearson's r - Faustregel

Tabelle 36: Interpretation von Pearson's r

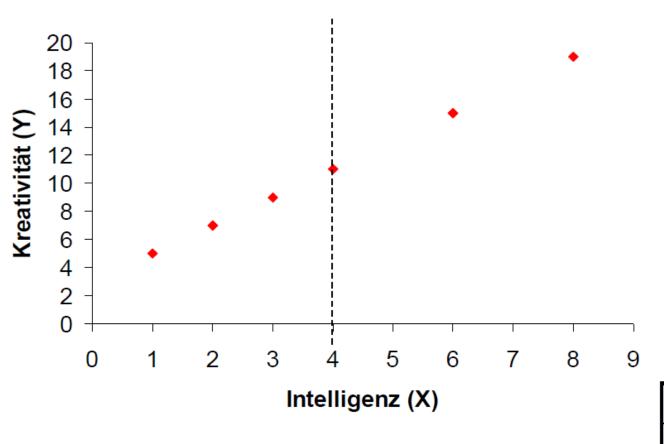
Korrelationskoeffizient (r)	Interpretation
≤ 0,05	kein Zusammenhang
$> 0.05 \text{ bis} \le 0.20$	schwacher Zusammenhang
$> 0.20 \text{ bis} \le 0.50$	mittelstarker Zusammenhang
$> 0.50 \text{ bis} \le 0.70$	starker Zusammenhang
> 0,70	sehr starker Zusammenhang

Quelle: Eigene Darstellung

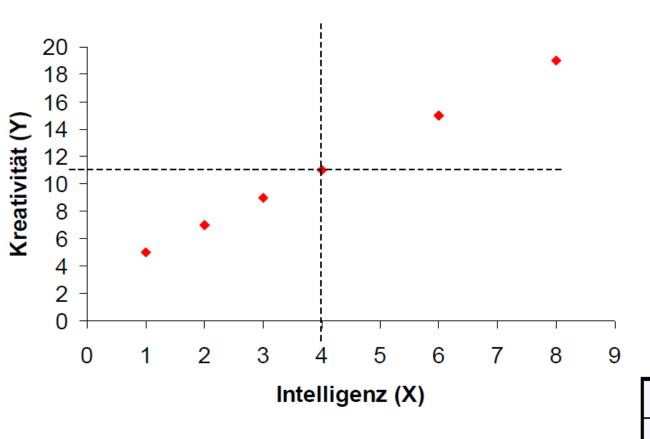
Aber: Die Beurteilung der Höhe einer Korrelation hängt immer von der zugrunde liegenden Fragestellung ab!



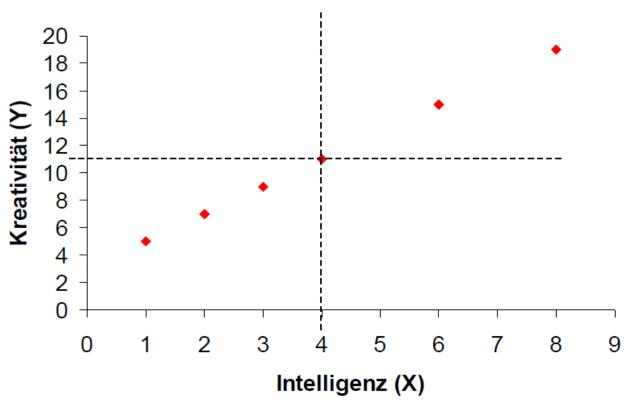
	X	Υ
	1	5
	2	7
	2	7
	3	9
	4	11
	6	15
	6	15
	8	19
<i>M</i> =	4	11
s² =	5,25	21



	X	Υ
	1	5
	2	7
	2	7
	3	9
	4	11
	60	15
	60	15
	8	19
M =	4	11
S ² =	5,25	21

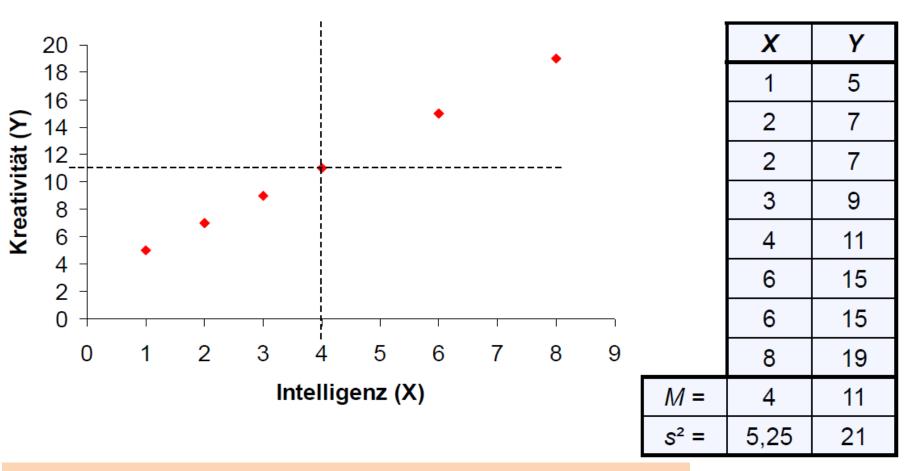


	X	Υ
	1	5
	2	7
	2	7
	3	9
	4	11
	6	15
	6	15
	8	19
<i>M</i> =	4	11
S ² =	5,25	21

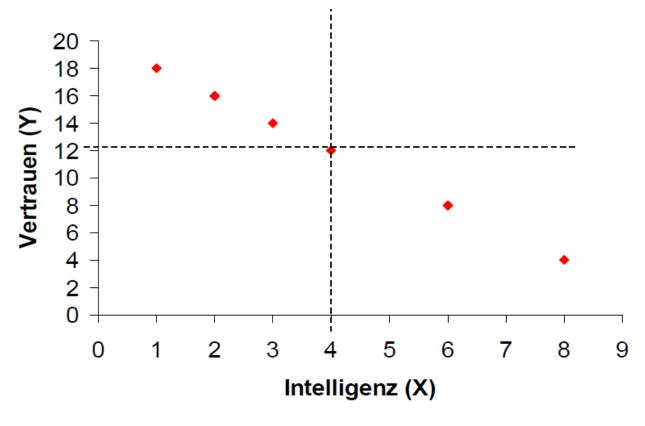


	X	Υ
	1	5
	2	7
	2	7
	3	9
	4	11
	6	15
	6	15
	8	19
M = s ² =	4	11
s ² =	5,25	21

Wann ist der Zusammenhang zwischen zwei Variablen X und Y positiv?

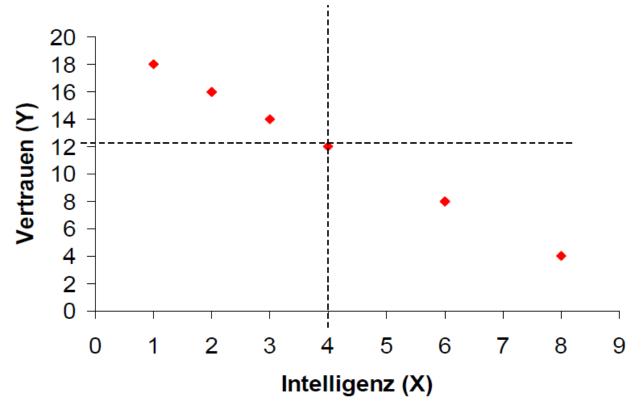


Zusammenhang X und Y dann positiv, wenn x-Werte> \bar{x} liegen, mit y-Werte > \bar{y} einhergehen (und umgekehrt)



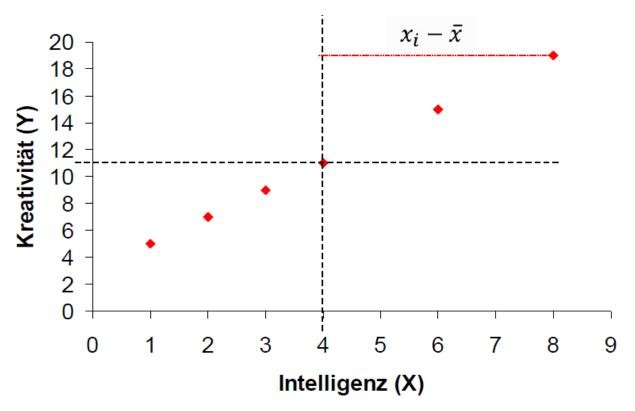
	X	Υ
	1	18
	2	16
	2	16
	3	14
	4	12
	6	8
	6	8
	8	4
M =	4	12
S ² =	5,25	21

Negativer Zusammenhang zwischen 2 Variablen X und Y?

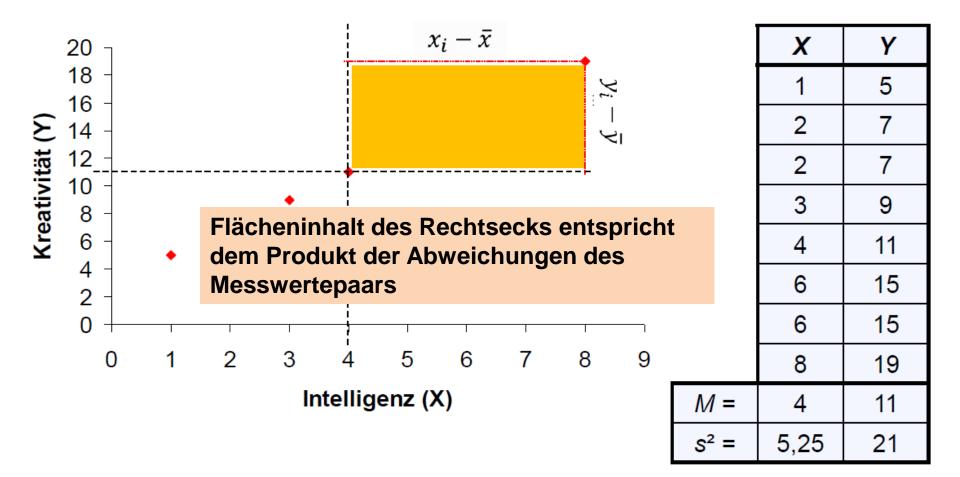


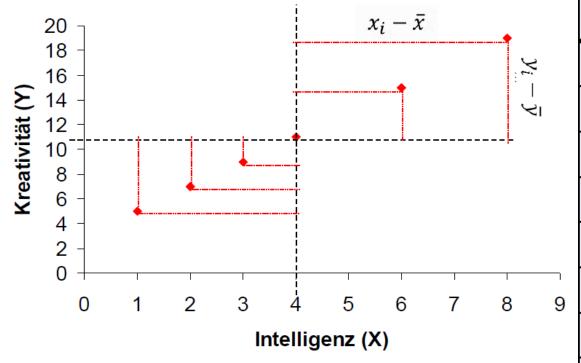
	X	Υ
	1	18
	2	16
	2	16
	3	14
	4	12
	6	8
	6	8
	8	4
M = s ² =	4	12
s ² =	5,25	21

Zusammenhang dann negativ, wenn zwischen 2 Variablen x-Werte $> \overline{x}$ einhergehen mit y-Werte $< \overline{y}$



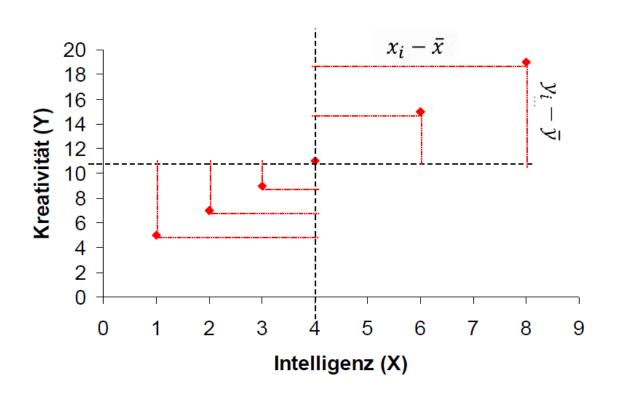
	X	Υ
	1	5
	2	7
	2	7
	3	9
	4	11
	6	15
	6	15
	8	19
M =	4	11
S ² =	5,25	21





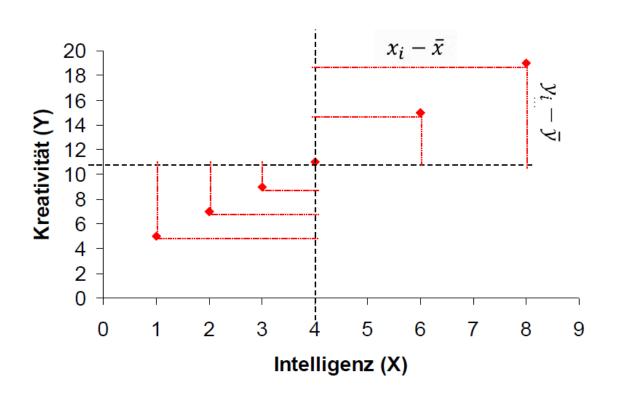
Schritt 1: Für jedes x_i sowie y_i wird Differenz vom jeweiligen arithmetischen Mittel berechnet

$x_i - \bar{x}$	$y_i - \bar{y}$
1 – 4 = -3	5 – 11 = -6
2 – 4 = -2	7 – 11 = -4
2 – 4 = -2	7 – 11 = -4
3 – 4 = -1	9 – 11 = -2
4 - 4 = 0	11 – 11 = 0
6 – 4 = 2	15 – 11 = 4
6 – 4 = 2	15 – 11 = 4
8 – 4 = 4	19 – 11 = 8



Schritt 2: Für jedes Wertepaar xy_i wird das *Kreuzprodukt*, d.h. das Produkt der Mittelwertsabweichung berechnet

$(x_i - \bar{x})(y_i - \bar{y}) =$			
-3	-6	18	
-2	-4	8	
-2	-4	8	
-1	-2	2	
0	0	0	
2	4	8	
2	4	8	
4	8	32	

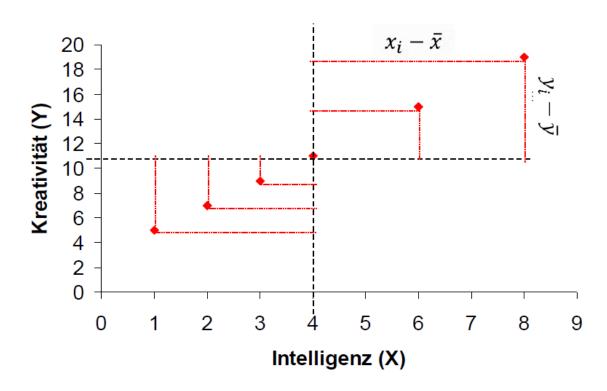


Schritt 3: Berechnung der Kreuzproduktsumme, d.h. die Summe aller Kreuzprodukte von i = 1 bis n

$(x_i - \bar{x})(y_i - \bar{y}) =$			
-3	-6	18	
-2	-4	8	
-2	-4	8	
-1	-2	2	
0	0	0	
2	4	8	
2	4	8	
4	8	32	

Summe: 84

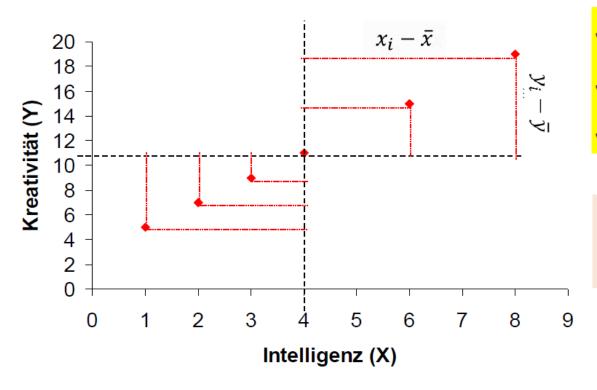
$$\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$$



Schritt 4: Berechnung Kovarianz, indem durch n geteilt wird ("mittleres Kreuzprodukt")

$(x_i-\bar{x})(y_i-\bar{y}) =$			
-3	-6	18	
-2	-4	8	
-2	-4	8	
-1	-2	2	
0	0	0	
2	4	8	
2	4	8	
4	8	32	
Sum	ime:	84	
Kova	rianz:	10,5	

 $\sum_{i=1}^{n} (x_i - \bar{x})(y_i - \bar{y})$



Schritt 5: Berechnung Pearson's r durch Relativierung der empirischen Kovarianz an der maximalen Kovarianz

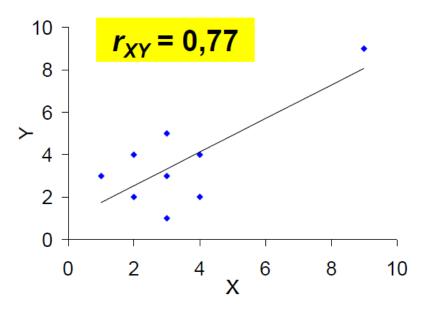
$$s_X^2 = 5,25$$
 $s_X = 2,29$
 $s_Y^2 = 21$ $s_Y = 4,58$
 $s_X \cdot s_Y = 2,29 \cdot 4,58 = 10,5$

$$r = \frac{Cov_{xy}}{s_x s_y}$$

$$r = \frac{10,5}{10.5} = 1$$

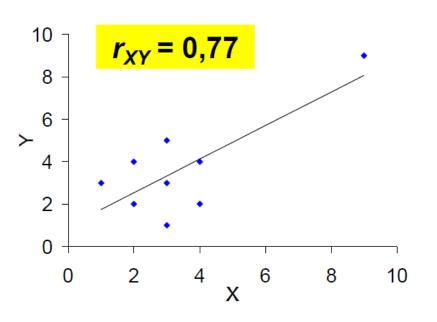
Pearson's r: Ergänzung

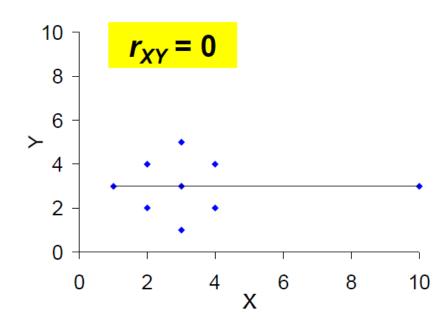
Korrelationskoeffizienten sind sensitiv gegenüber Ausreißern und Extremwerten, v.a. bei kleinen Stichproben



Pearson's r: Ergänzung

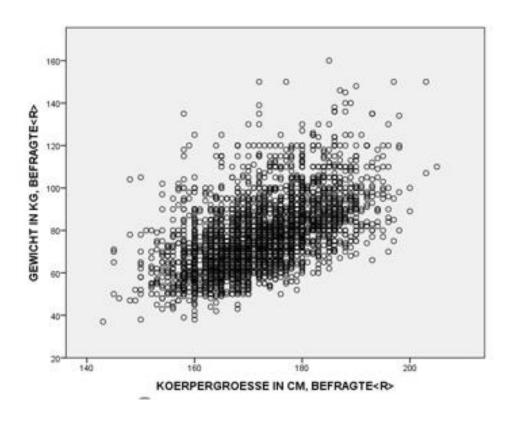
Korrelationskoeffizienten sind sensitiv gegenüber Ausreißern und Extremwerten, v.a. bei kleinen Stichproben



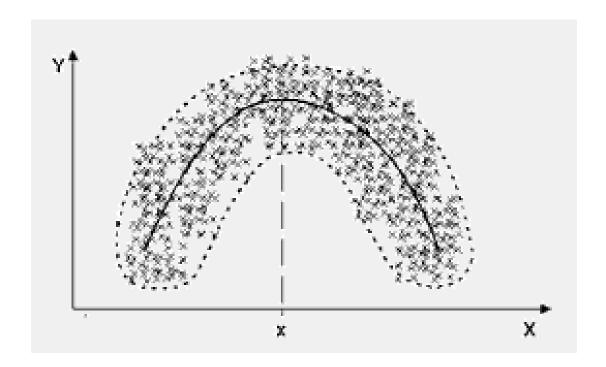


Zusammenhangshypothese: "Je größer man ist, desto schwerer ist man auch" (Streudiagramm erstellt auf Basis des Allbus 2016)

r=0,547



Keine lineare Korrelation! r=0 (Bsp. Leistungsfähigkeit und Anspannung während Klausur)

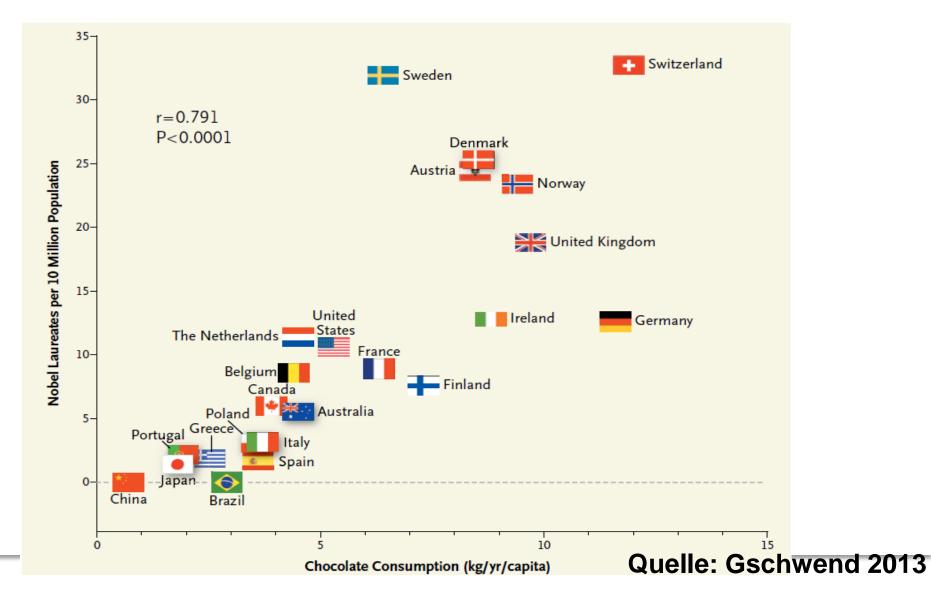


Pearson's r: Übung

- 1) Zeichnen Sie ein Streudiagramm
- 2) Berechnen Sie Pearson's r
- 3) Interpretieren Sie das Ergebnis

	x_i	\boldsymbol{y}_i	$(x_i-\overline{x})$	$(y_i - \overline{y})$	$(x_i - \overline{x})(y_i - \overline{y})$	$(x_i - \overline{x})^2$	$(y_i - \overline{y})^2$
Α	0	2					
В	10	6					
C	4	2					
D	8	4					
Е	8	6					

- Korrelationsberechnung braucht inhaltliche Theorie bzw. Plausibilität!
- Korrelation ≠ Kausalität!



- Zusammenhänge zwischen (pseudo-)metrischen Merkmalen
 - Allgemein
 - Hypothesen
 - Grafische Veranschaulichung
 - Zusammenhangsmaß Pearson's Rho
- Zusammenhangsmaß zwischen metrischem und gruppiertem Merkmal: PRE-Maß η 2 (Eta-Quadrat)

Wiederholung PRE-Maße

- PRE: "Proportional Reduction of Error"
- Verschiedene PRE-Maße in der Statistik
- Ausgangsfrage: Wie gut können die Werte einer abhängigen Variable durch die Werte einer unabhängigen Variable vorhergesagt werden?
- Folgen der gleichen Logik
- Setzen eine "gerichtete" Hypothese voraus, d.h. wir kennen abhängige und unabhängige Variable

Wiederholung PRE-Maße

Schrittweises Vorgehen:

- 1) Wie lautet die Prognose des Wertes der abhängigen Variable **ohne** Kenntnis der unabhängigen Variablen? (Vorhersagefehler E1)
- Prognose des Wertes der abhängigen Variable mit Kenntnis der Verteilung der unabhängigen Variable (Vorhersagefehler E2)
- 3) Ermittlung des PRE-Maßes und Aussage, ob die Vorhersage durch die unabhängige Variable verbessert wurde PRE = (E1 E2) / E1

Je nach PRE-Maß werden die Fehler dabei unterschiedlich berechnet

- Auch Eta-Koeffizient
- Abhängige Variable muss mind. (pseudo-) Intervallskalenniveau aufweisen
- Unabhängige Variable kann beliebiges (aber gruppiertes) anderes Niveau aufweisen

- Berechnung basiert auf Quadratsummen
- Quadratsumme stellt die Summe der quadrierten
 Abweichungen vom arithmetischen Mittelwert eines Merkmals dar
- Verschiedene Quadratsummen werden unterschieden:
 - "Quadratsumme Gesamt": Entspricht der Summe aller quadrierten Abweichungen vom Mittelwert der (abhängigen) Variable (Vorhersagefehler E1).
 - "Quadratsumme innerhalb": Wird die unabhängige Gruppenvariable berücksichtigt, wird innerhalb der Gruppen berechnet, wie stark die Gruppenmittelwerte vom Gesamtmittelwert abweichen (Vorhersagefehler E2).
 - "Quadratsumme zwischen": "Quadratsumme Gesamt"-"Quadratsumme innerhalb"

$$PRE = (E1 - E2) / E1$$

$$\eta 2 = \frac{Quadratsumme \ Gesamt - Quadratsumme \ innerhalb}{Quadratsumme \ Gesamt} = \frac{Quadratsumme \ Zwischen}{Quadratsumme \ Gesamt}$$

Politisches Wissen von Schüler*innen mit und ohne Migrationshintergrund

ID	Migrationshintergrund	Politisches Wissen (y_i)
1	1 (Nein)	15
2	2 (Ja)	10
3	2 (Ja)	2
4	2 (Ja)	9
5	1 (Nein)	7
6	1 (Nein)	16
7	1 (Nein)	14
8	2 (Ja)	6
9	2 (Ja)	4
10	1 (Nein)	12

Quelle: Eigene Darstellung

Arithmetisches Mittel: 9,5

Schritt 1

 Arithmetisches Mittel als bester Vorhersagewert, wenn keine unabhängige Variable berücksichtigt wird

Schritt 2

Berücksichtigung uV

Schritt 3

Ermittlung Eta-Koeffizient

Tabelle 43: Arbeitstabelle Migrationshintergrund und politisches Wissen

ID	Migrations- hintergrund	Politisches Wissen (y _i)	$y_i - \bar{y}$	$(y_i - \bar{y})^2$
1	1 (Nein)	15	5,5	30,25
2	2 (Ja)	10	0,5	0,25
3	2 (Ja)	2	-7,5	56,25
4	2 (Ja)	9	-0,5	0,25
5	1 (Nein)	7	-2,5	6,25
6	1 (Nein)	16	6,5	42,25
7	1 (Nein)	14	4,5	20,25
8	2 (Ja)	6	-3,5	12,25
9	2 (Ja)	4	-5,5	30,25
10	1 (Nein)	12	2,5	6,25
		∑ = 95		Σ = 204,5
		$\bar{y} = 9.5$		

Quelle: Eigene Darstellung

E1: Quadratsumme Gesamt

ID	Migrations- hintergrund	Politisches Wissen (y _i)	$y_i - \bar{y}$	$(y_i - \bar{y})^2$
1	1 (Nein)	15	2,2	4,84
5	1 (Nein)	7	-5,8	33,64
6	1 (Nein)	16	3,2	10,24
7	1 (Nein)	14	1,2	1,44
10	1 (Nein)	12	-0,8	0,64
		∑ = 64		$\sum = 50.8$
		$\bar{y} = 12.8$		

Quelle: Eigene Darstellung

Quadratsumme Gruppe "Nein"

ID	Migrations- hintergrund	Politisches Wissen (y_i)	$y_i - \bar{y}$	$(y_i - \bar{y})^2$
2	2 (Ja)	10	3,8	14,44
3	2 (Ja)	2	-4,2	17,64
4	2 (Ja)	9	2,8	7,84
8	2 (Ja)	6	-0,2	0,04
9	2 (Ja)	4	-2,2	4,84
		∑ = 31		$\Sigma = 44.8$
		$\overline{y} = 6.2$		

Quelle: Eigene Darstellung

Quadratsumme Gruppe "Ja"

$$\eta 2 = \frac{Quadratsumme \ Gesamt - Quadratsumme \ innerhalb}{Quadratsumme \ Gesamt} = \frac{Quadratsumme \ Zwischen}{Quadratsumme \ Gesamt}$$

E2: 44,8+50,8=95,6

$$\eta 2 = \frac{E1 - E2}{E1} = \frac{204,5 - (50,8 + 44,8)}{204,5} = \frac{204,5 - 95,6}{204,5} = \frac{108,9}{204,5} = 0.53$$

Schätzfehler kann um 53% vermindert werden, wenn wir die uV berücksichtigen

Kann Werte zwischen 0 und 1 annehmen

Tabelle 41: Interpretation von Eta-Quadrat

Eta-Quadrat	Interpretation	
< 0,01	kein Effekt	
0,01 bis < 0,06	kleiner Effekt	
0,06 bis < 0,14	mittlerer Effekt	
≥ 0,14	großer Effekt	

Quelle: Eigene Darstellung

ID	Taschengeld pro Monat in Euro	Gruppe
1	3	1
2	9	2
3	10	1
4	4	2
5	2	1
6	4	1
7	3	2
8	6	1
9	5	2
10	6	2

Sie wollen untersuchen, ob ältere Grundschulkinder tatsächlich mehr Taschengeld bekommen als jüngere und haben dazu folgende Daten ermittelt und zwei Kinder-Gruppen gebildet: 1: Klasse 1 und 2 vs. 2: Klasse 3 und 4 – Berechnen Sie Eta-Quadrat und interpretieren Sie das Ergebnis!

Berechnung

Messniveau	nominal	ordinal	metrisch
nominal	Chi-Quadrat, Cramer's V Lambda C	Cramer's V Lambda C	Eta-Koeffizient Mittelwertvergleich (t-test)
ordinal	Cramer's V Lambda C	Spearman's Rho; (Kendalls Tau B) gamma	Spearman's Rho; (Kendalls Tau B) gamma
metrisch	Eta-Koeffizient Mittelwertvergleich (t-test)	Spearman's Rho; (Kendalls Tau B) gamma	Pearson's r

Darstellung

Messniveau	nominal	ordinal	metrisch
nominal	Kreuztabelle	Kreuztabelle	(gruppierte) Boxplots
ordinal		Kreuztabelle	(gruppierte) Boxplots
metrisch			Streudiagramm

Was können bivariate Analysen leisten?

- Beschreibung der Zusammenhänge zwischen 2 Variablen
- Kreuztabellen und die damit verbundenen Maße (Chi-Quadrat, Cramers V) können Auskunft über Zusammenhänge zwischen nominalen Variablen liefern
- Korrelationskoeffizienten (Spearman/Pearson) beschreiben die Stärke "gleichsinniger" oder gegenläufiger Zusammenhänge zweier Variablen
- PRE-Maße (Lambda, Eta) geben an, inwieweit eine unabhängige
 Variable durch Einbezug einer weiteren Variable "besser" erklärt wird

- Überprüfen, inwieweit die Zusammenhänge zwischen zwei Variablen womöglich noch von weiteren Variablen abhängig sind
- Mehrere unabhängige Variablen in ihrem gemeinsamen Einfluss auf eine abhängige Variable untersuchen
- Kausalitätsrichtung bestimmen